



2026-1 ML 기초 토이프로젝트

전월세 통합 가격 지표 기반 대학생 주거 매물 적정성 예측 모델

2조 | 김희광, 강경래, 김주연, 박가영, 신연호, 이수련, 이채희

Contents

- 01 프로젝트 배경
 - 프로젝트 배경
 - 프로젝트 목표
- 02 데이터 수집
 - 데이터 수집
 - 데이터 전처리
 - 최종 데이터셋
- 03 데이터 분석
 - 피처 엔지니어링
 - 모델링
 - 모델 평가
- 04 한계점 및 개선방안
 - 한계점
 - 개선방안

프로젝트 배경

프로젝트 배경

기사 1

「닭장인데 50만원.. ‘원룸플레이션’에 고통받는 사람들」 - MBC

- 경상국립대 인근 ‘닭장형 원룸’, 학교 인근이라는 이유로 월세 약 53만 원 수준
- 월세 대신 관리비를 사실상 월세 수준으로 인상하는 사례 다수

기사 2

「“학교 근처에 방이 없어요”...취준생, 직장인들의 대학가 점령」 - 주간한국

- 취업 한파로 취준생이 증가하면서 기존 거주 학생들의 계약 연장 증가
- 직장인들도 비교적 저렴한 대학가 원룸을 선호하여, 정작 대학생의 주거 확보가 어려워짐

기사 3

「서울 대학생 10명 중 1명, 월세 70만원 이상 낸다... “비싼데 상태는 별로”」 - 네이트뉴스

- 자취 중인 대학생의 49%가 주거 환경에 불만족
- 자취방 선택 시 신축 및 편의시설을 중시하지만, 기대에 못 미치는 매물 다수 존재



프로젝트 목표

자취를 시작하는 대학생이 직면한 문제들

월세 상승세

대학생 부담을
가중시키는
월세 인플레이션

매물 가뭄

학교 인근 원룸의
빠른 매물 소진

불량 매물

높은 가격 대비
낙후된 주거 환경




주택의 적정 가격 수준 예측 모델을 통한 해결 ✓

데이터 수집

주택 유형별 매물 분류

연립/다세대



- 개별 세대별로 하나의 주택으로 취급
- 연면적 660㎡ 초과 시 연립, 이하 시 다세대
- 4층 이하



세대별 소유가 가능한 공동주택

단독/다가구



- 건물 전체를 하나의 주택으로 취급
- 한 세대 거주 시 단독, 여러 세대 거주 시 다가구
- 3층 이하



건물 단위로 소유되는 주택

오피스텔



- 준주택: 법적으로 주택이 아닌 업무시설
- 주거 기능을 겸한 업무시설



주거가 가능한 업무시설

주택 유형에 따른 데이터 수집

The screenshot displays the KHODA real estate data collection interface. The top navigation bar includes links for '아파트' (Apartment), '연립/다세대' (Attached/Row House), '단독/다가구' (Detached/Row House), '오피스텔' (Office Tel), '토지' (Land), '분양/입주권' (New Development/Residence Right), '상업/업무용' (Commercial/Office Use), and '공장/창고 등' (Factory/Warehouse, etc.). The main content area shows a search filter section with the following details:

- 매매** (Sale) / 전월세 (Monthly Rental)
- 계약일자** (Contract Date): 2025. 02. 23. - 2026. 02. 22.
- 지번구분** (Parcel Classification): 지번주소 (Parcel Address) / 도로명주소 (Road Name Address)
- 읍면동** (Myeon/Dong): 영통동 (Yeongtong-dong)
- 면적** (Area): 전체 (Total)
- 단지명** (Complex Name): 전체 (Total)
- 금액** (Amount): 최소금액(만원) (Minimum Amount in 10,000 KRW) - 최대금액(만원) (Maximum Amount in 10,000 KRW)

Buttons for 'EXCEL 다운' (Download Excel) and 'CSV 다운' (Download CSV) are visible at the bottom of the filter section.



1 단독/다가구 데이터의 특징

- 번지 정보가 마스킹되어 위치 정밀도에 한계 존재
- 층(FLOOR)피처가 제공되지 않아 층 관련 분석에 제약

2 연립/다세대 데이터의 특징

- 위치 및 건물 정보가 비교적 상세하게 제공
- 다만 전체 데이터셋 규모는 상대적으로 부족

3 오피스텔 데이터의 특징

- 위치 및 건물 정보가 충분히 확보됨
- 층(Floor) 피처가 다양하게 분포 (10층 이상 포함)

문제 정의 및 해결 전략

PROBLEM

SOLUTION

1

전세·월세 단위 불일치

전월세 환산 공식 적용
-> 비교 가능한 단일 가격 지표 생성

2

피처 선정 기준 부재

논문 기반 핵심 피처 선정
+ 사용자 관점 생활 인프라 반영 ex)국제캠퍼스까지의 거리

3

거리 API 연산 시간 과다
(약 2,200여건의 개별 계산 부담)

DBSCAN 기반 클러스터링
2,200여개의 좌표를 34개의 대표 좌표로 압축

공간 의존성 기반 피처 분류

피처의 공간 의존성 여부에 따라 처리 방식을 구분

피처 특성에 따라 공간 집계 기반 변수와 원본 속성 변수를 분리 처리

클러스터링 적용

주변 입지 특성을 반영하기 위해
위치 기반 피처에 클러스터링 활용


- 거리 및 이동시간 관련 변수
- 생활 인프라 개수 피처 (CCTV, 방범등 등)

클러스터링 미적용

매물의 고유 속성이므로
원본 값을 그대로 사용

- 건축년도
- 향
- 층

클러스터링 기법 채택 과정



1 KMeans

Silhouette: 0.551

DBI: 0.648

CH: 2644.1

2 GMM

Silhouette: 0.540

DBI: 0.647

CH: 2549.6

3 DBSCAN

Silhouette: 0.541

DBI: 0.358

CH: 4412.4


4 MeanShift

Silhouette: 0.641

DBI: 0.302

CH: 2377.3

클러스터링 기법 채택 과정



1 KMeans

Silhouette: 0.551

DBI: 0.648

CH: 2644.1

2 GMM

Silhouette: 0.540

DBI: 0.647

CH: 2549.6

3 DBSCAN

Silhouette: 0.541

DBI: 0.358

CH: 4412.4

4 MeanShift

Silhouette: 0.641


DBI: 0.302

CH: 2377.3

클러스터링 기반 피쳐 생성 파이프라인

클러스터링 기반 피쳐 생성 과정

모델 입력을 위한 위치 기반 파생 피쳐 체계 구축



- 약 2,200개 매물을 34개 클러스터로 압축 (cluster_id: 0.0 ~ 33.0)
- 군집 중심 기반 대표 좌표 추출
- 거리 계산 효율성 확보

- 각 클러스터의 중심 좌표 계산
- 대표 주소-좌표 매핑 수행
- 거리 계산 기준으로 활용


- 대표 좌표 ↔ 주요 지점 간 거리 계산
- API 기반 이동 시간 산출
- 원본 데이터프레임에 피쳐로 반영

- 생활 인프라 개수 피쳐 추출
- 최종 모델 입력 데이터셋 구성

데이터 전처리

모델 성능 향상을 위한 체계적 데이터 전처리 수행

데이터 품질 개선을 통해 모델 학습 안정성 확보



총 2,212개 샘플 · 38개 피처로 구성된 최종 데이터셋


[illegible]

데이터 분석

피처 엔지니어링




상관관계 히트맵 & VIF 분석



상관구조 분석 결과

- 변수 간 높은 상관관계 존재 확인
- 다중공선성으로 인한 모델 성능 저하 가능성 검토
- 거리-개수, 거리-시간 변수 간 밀접한 연관성 확인
- 편의시설, CCTV, 보안등 설치 개수 간 높은 유사성 확인



다중공선성 진단 결과

- VIF 기준치(10) 초과 변수 식별
- 독립 변수 간 중복성 판단 및 제거 대상 선정
- CCTV, 보안등 중첩반경(100m, 300m) 피쳐 정리
- 편의시설, 약국 등 유사 속성 피쳐 통합 검토
- 도보, 교통수단 관련 중복 피쳐 정리

피처 엔지니어링



피처 엔지니어링

Problem

01 인프라 관련 변수 편중

병원, 편의점, 주차장 등 개수 기반 피처들간의 높은 상관성 확인

02 유사 측정 지표의 중복

CCTV, 보안등(Lamp) 등 거리별 측정값이 유사한 속성으로 분포

03 변수 팽창 문제

성격이 중복되는 피처로 인해 VIF가 급격히 상승하여 모델 신뢰도 저하

Solution

LifeinfraScore 피처

개별 count 변수들을 통합하여 하나의 'LifeinfraScore'로 지수화


SecurityScore 피처

클러스터 중심 기준으로 300m 이내의 CCTV 및 보안등 개수를 합산하여 'SecurityScore'로 파생 피처 생성

SchoolAccess 피처

학교까지의 거리, 도보 시간을 결합한 'SchoolAccess' 피처로 단일화

Output



모델 선정

후보 모델

RandomForest



XGBoost



LightGBM



후보 모델별 특징

노이즈 및
이상치에 강함

- 다수 트리 예측값을 평균하는 배깅(Bagging) 구조
- 극단적 이상치에 대한 민감도 낮음
- 안정적인 기준 성능 제공

높은
예측 정확도

- 이전 모델의 오차를 순차적으로 보완하는 부스팅(Boosting) 방식
- 역세권 거리, 건축 연식 등 비선형 패턴 학습에 강점
- 복잡한 관계를 정밀하게 모델링 가능


대용량 데이터
처리 효율

- 오차가 큰 리프를 우선적으로 분할하는 Leaf-wise 성장 방식
- 대규모·고차원 데이터에서 빠른 학습 속도
- 부동산 데이터와 같은 복잡한 구조에 효율적


모델 신뢰도 확인

핵심 가격 결정 요인의 모델 반영 여부 검증


피쳐 중요도 분석 결과가 기존 연구에서 제시된 핵심 가격 결정 요인과 전반적으로 일치함을 확인



RandomForest 피쳐 중요도




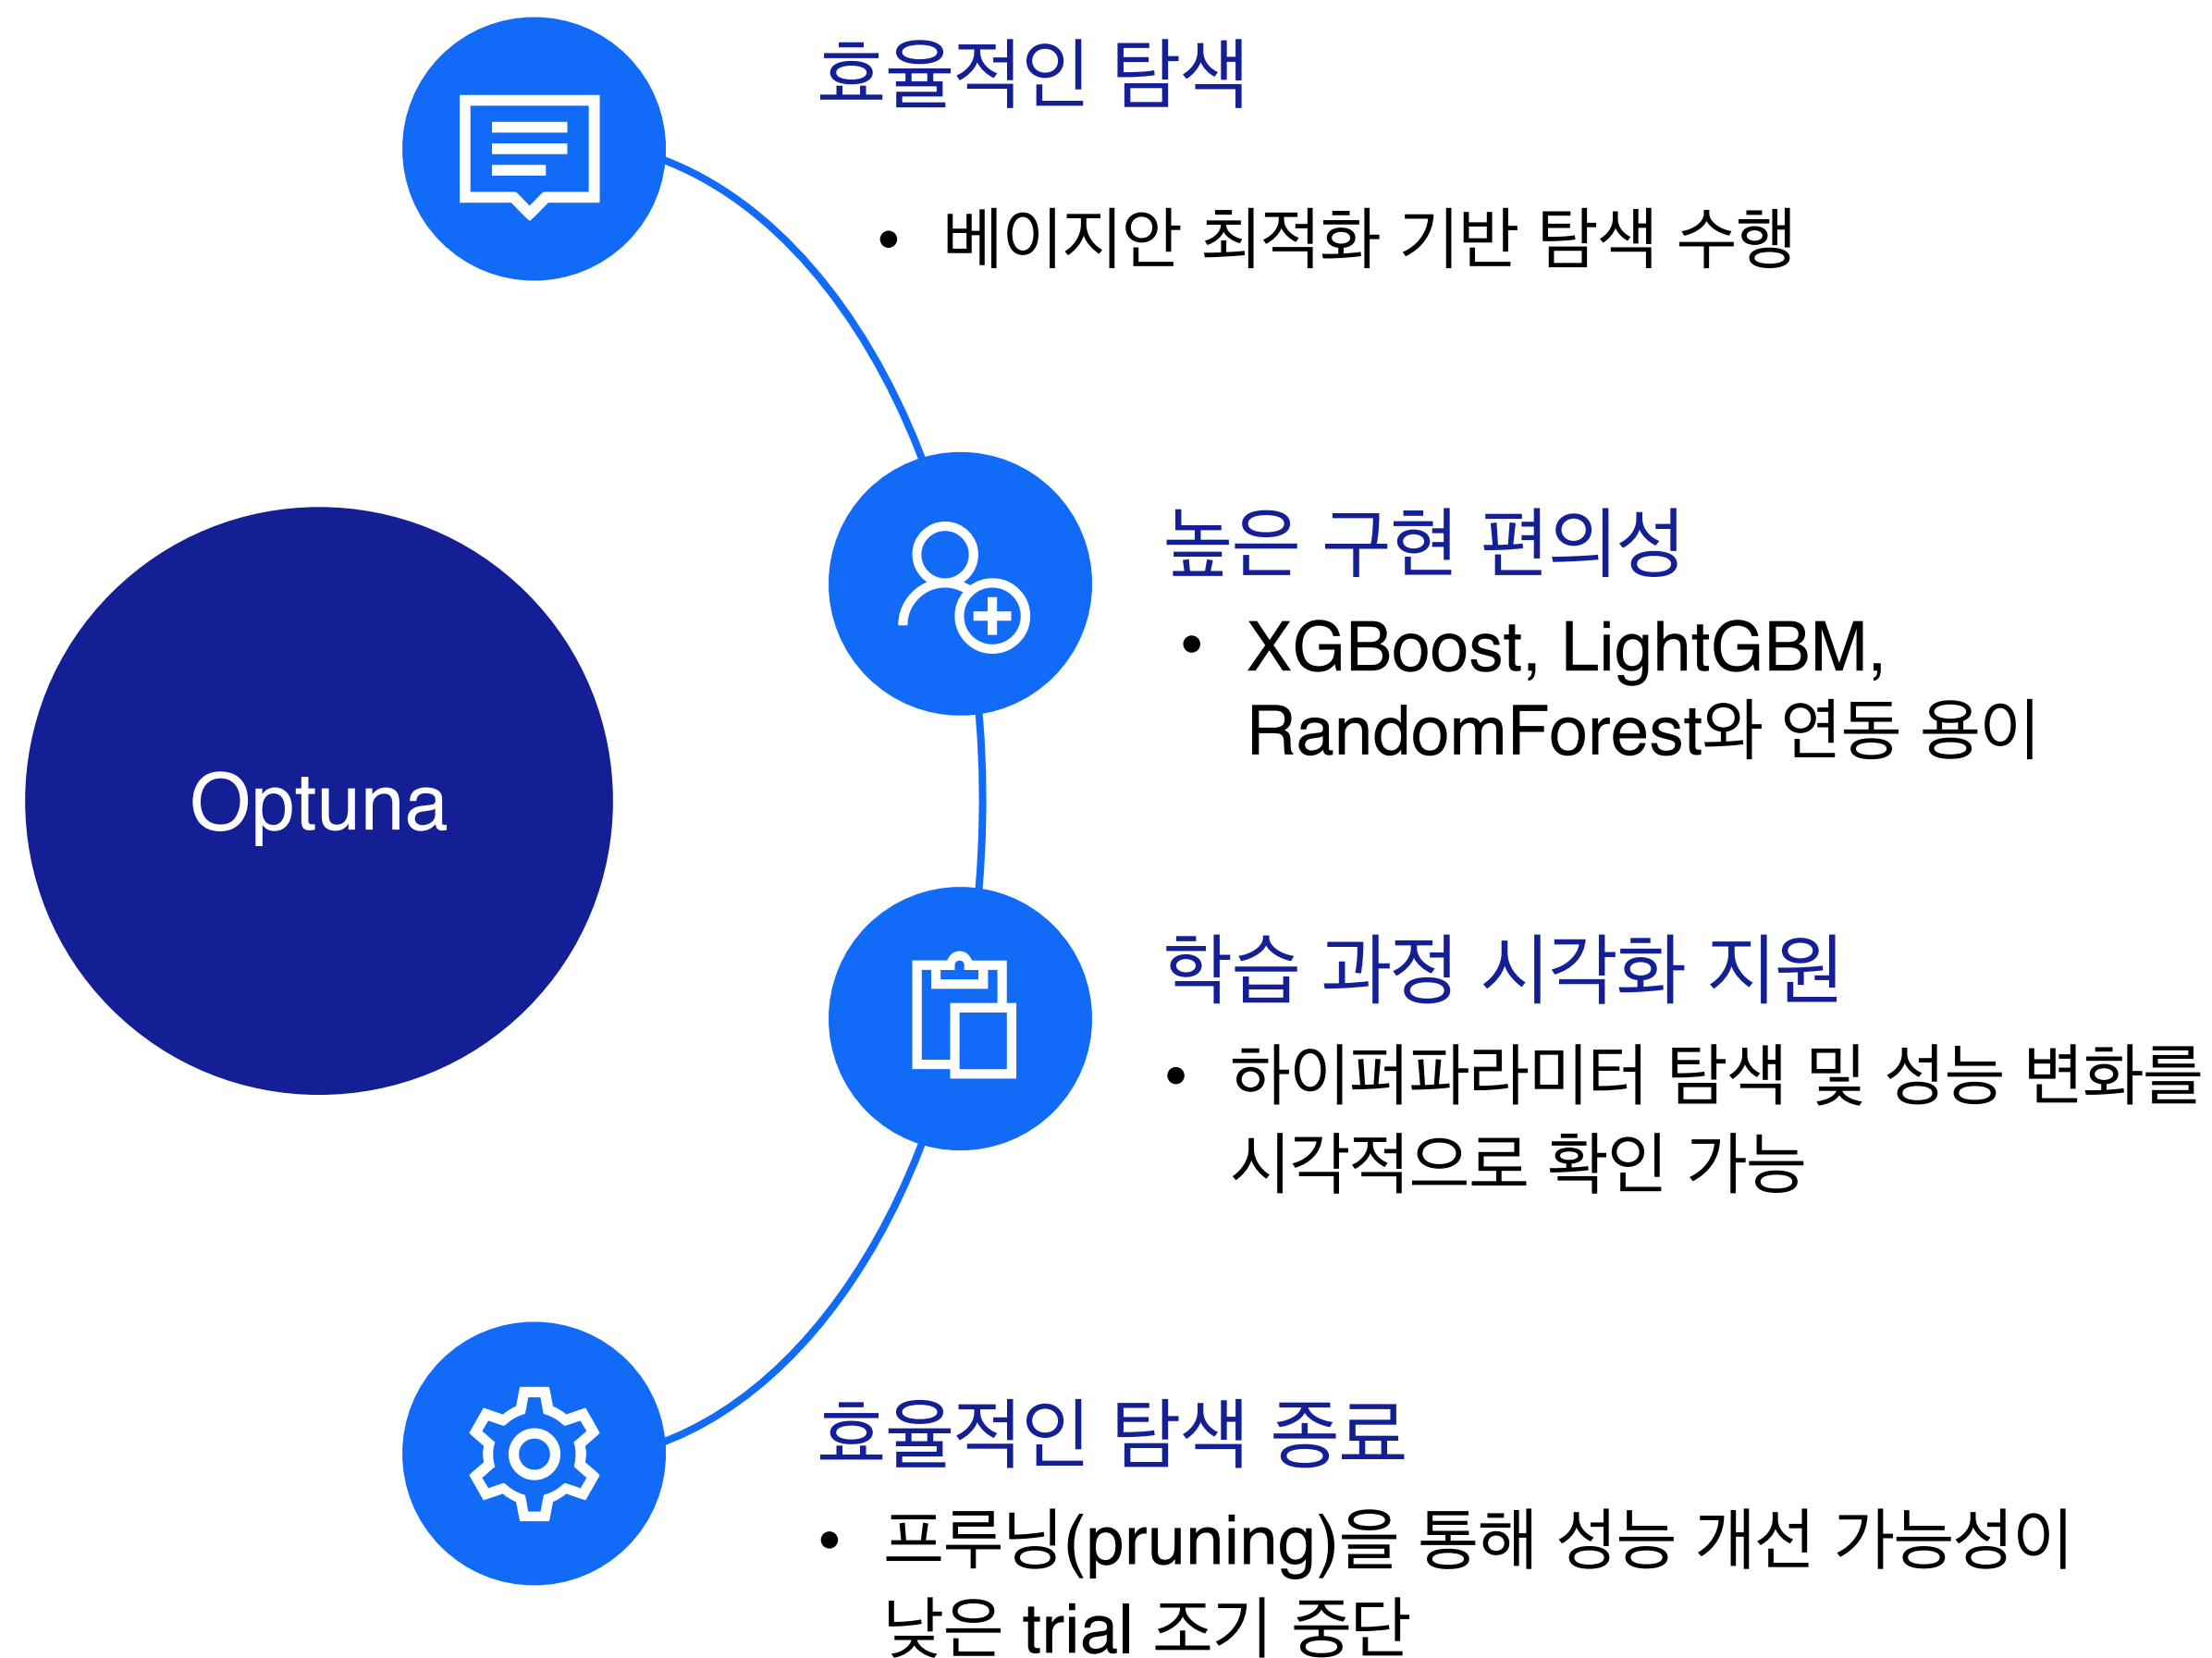
XGBoost 피쳐 중요도



LightGBM 피쳐 중요도


하이퍼파라미터 튜닝

Optuna 기반 모델 최적화




모델 성능 향상 전략

스태킹 앙상블 기반 성능 개선



최종 모델 선정 근거

RMSE (만원) - 낮을수록 좋음




RMSE

평균 제곱근 오차

잔차 제곱의 평균에 제곱근을 취한 값
값이 작을수록 예측 오차가 작음을 의미

MAPE (%) - 낮을수록 좋음




MAPE

평균 절대 백분율 오차

실제값 대비 오차의 백분율 평균
값이 작을수록 상대적 예측 오차가 작음


MAE (만원) - 낮을수록 좋음



MAE

평균 절대 오차

실제값과 예측값 차이의 절대값 평균
값이 작을수록 예측 오차가 작음

R² Score - 높을수록 좋음R²

결정계수

모델이 데이터 변동성을 설명하는 비율
값이 클수록 모델의 설명력이 높음

최종 모델 선정

최적 모델:

RandomForest(Optuna)

모델 성능

- R^2 0.79 / RMSE 1682
- MAE 1037 / MAPE 10.6
- 전 지표 기준 가장 우수

피처 중요도 검증


- 연식, 전용면적 등 핵심 변수 논문 기반 가격 결정 요인과 일치
- 모델 학습 방향의 타당성 확인

데이터 특성 적합성

- 데이터 변동성과 타깃 분산이 큰 구조
- 안정적인 단일 모델 구조에 적합
- 복합 모델 대비 적용 효율 우수

앙상블 가중치 근거

- RF 0.503 / LGB 0.422 / XGB 0.074
- 메타 모델 기준 RF 기여도 최대
- 앙상블 내 핵심 모델로 확인



평가지표의 실무적 해석

R^2 0.79
환경 요인을 반영한
합리적 설명력 확보

주관적 호가가 아닌
데이터 기반 가격 기준 제시

일반 매물 협상 범위
(5~10%)와 유사한
수준의 오차

MAPE 10.6%
실거래 협상
범위 내 오차

MAE 1037
실거래 수준의 평균 오차

4천만 ~ 2억원
거래 구간 기준
평균 약 1,000만 원 오차
실무 수용 가능한 수준

특이 매물을 포함하더라도
최대 오차 변동폭 관리 가능

RMSE 1682
이상치 포함
최대 오차 수준

매물 가격 적정성 분석 결과

RandomForest(Optuna) 모델 기반 실거래 데이터 적용

네이버 부동산 실거래 데이터를 크롤링·수집하여 모델 검증에 활용

매물 ID	보증금/월세	위치 정보	매물 특성	가격 적정성
매물 1	1000/75	위도: 37.25154 경도: 127.0772	전용면적(m²): 26.08 층수: 6 향: 북동향	상향(비쌈)
매물 2	200/30	위도: 37.2535 경도: 127.0778	전용면적(m²): 26 층수: B1 향: 남서향	하향(저렴)
매물 3	300/38	위도: 37.25037 경도: 127.074	전용면적(m²): 19.83 층수: ? 향: 남향	적정
매물 4	7500/0	위도: 37.25012 경도: 127.0738	전용면적(m²): 25 층수: 2 향: 남서향	상향(비쌈)

한계점 및 개선방안

프로젝트 한계점 및 개선 방향


데이터, 피처, 모델 측면의 구조적 한계 점검

프로젝트 전반의 한계를 진단하고 향후 개선 방향을 도출



데이터 범위의 한계

단독·다가구 중심의 편중된 데이터셋, 플랫폼 API 한계로 내부 옵션 정보 부족, 실제 거주 선호를 반영한 생활 편의 데이터 미흡



파생 피처 가중치 단순화

파생 피처 합산 과정에서 동일 가중치 적용, 실제 가격 영향도 차이를 충분히 반영하지 못함

→ 향후 상관 기반 가중치 또는 차원 축소 기법 적용 필요



모델 다양성의 제한

사용 모델이 트리 계열에 편중, 스택킹 시 모델 간 다양성 확보 한계

→ Ridge, KNN 등 이질 모델 추가로 개선 가능

감사합니다!